

ChatGPTの "T" を知る

Transformer入門

坪井 一馬

2026年9月19日 @法政大学多摩キャンパス



目次

- 1 自己紹介
- 2 GPT とは？
- 3 GPT の作り方, 動かし方
- 4 GPT には目と耳がある？
- 5 それでも間違う！
- 6 まとめ

坪井 一馬 Kazuma TSUBOI



学科の友人との飲み会
ハイボールで笑顔



名古屋・矢場味仙
行くたびに辛さが違う



仙台・牛タン定食
3000円払う価値がある



広島・お好み焼き
こっちが正しいお好み焼き

● INTP 論理学者

- 21 歳，神奈川県出身，実家暮らし
- 横浜国立大理工学部，化学・生命系学科，化学 EP
 - 研究テーマ「自然言語指示に基づく分子生成モデルの開発」
 - 大学院は内部進学予定です。
- 東京大学松尾・岩澤研究室で共同研究インターン
- Lumos 運営，機械学習 PJ 主宰者，システムチームメンバー
- 以前所属のサークルでケーブルテレビ局の番組制作のリーダーをしていました。
- 趣味は様々：旅行/コーヒー/酒/ゲーム/ラーメン/激辛/ご当地グルメ/名古屋メシ/喫茶店の雰囲気/離島でゆっくり流れる時間を過ごす

ChatGPT って何？

もしも、あなたが小学生に「ChatGPT って何？」と質問されたら、どのように答えますか？

- 何でも質問できる AI？
- 文章を作ってくれる AI？
- ものすごく物知りの AI？

学術的な正体

GPT は **Generative Pre-trained Transformer** の略である.

- **Generative**
 - 新しい文章を生成する
- **Pre-trained**
 - 大量のデータを使って, あらかじめ学習する
- **Transformer**
 - 文章などの情報を扱うニューラルネットワーク

生まれる疑問

では、GPT の正体を知ると、いくつか疑問が生まれる。

- なんで「何を質問しても知っている」のか
- なんで「テキストだけではなく画像なども扱える」のか
- なんで「間違えることがある」のか

この3つの疑問から、GPT の仕組みを見てみる。

コンピュータは文章を読めない

コンピュータは、私たちと同じように文字を読んでいるわけではない。

例えば、

「今日は大学で勉強する」

という文章も、そのままでは計算できない。

- 文章を小さな単位に分割する
- それぞれを数字として表現する
- その数字を使って計算する

文章を「トークン」に分ける

GPT では、文章をトークン (token) と呼ばれる単位に分けて扱う。

例えば、

「今日は大学で勉強する」

を、

「今日」 / 「は」 / 「大学」 / 「で」 / 「勉強」 / 「する」

のような単位に分割する。

- 必ずしも「1 単語 = 1 トークン」ではない
- GPT はトークン単位で文章を処理する

ことばを数字にする

トークンを, コンピュータが計算できる**数字の並び**に変換する.

- 「猫」 → 数字の並び
- 「犬」 → 数字の並び
- 「自動車」 → 数字の並び

このような数値表現を**埋め込み (Embedding)** と呼ぶ.

意味や使われ方が似たものは, 数値表現も似るように学習される.

でも、単語だけでは意味が分からない

同じ言葉でも、周囲の文章によって意味が変わる。

例えば、

- Apple を食べる
- Apple が新製品を発表する

「Apple」という文字だけでは、果物なのか会社なのか決められない。

そこで必要になるのが、

「周りのどこを見ればよいか？」

という考え方である。

Attention : どこを見る？

Transformer の中心となる仕組みが **Attention** である.

Attention では,

「ある単語を考えると、他のどの単語をどれくらい見るか」

を計算する.

例えば,

太郎は花子に本を渡した。彼女は喜んだ。

という文章では,

- 「彼女」と「花子」の関係
- 「渡した」と「本」の関係

などを考えながら文章を処理する.

Transformer が文脈を作る

Attention によって、単語は周囲の情報を取り込む。

- 単語そのものの情報
- 周囲の単語との関係
- 文章全体の文脈

を使って、各トークンの表現を更新していく。

Transformer では、このような処理を何層も繰り返す。

文章を読みながら、文脈に応じて表現を作り直していく

GPT が学んでいること

GPT の基本的な学習は、実は非常にシンプルである。

「次に来るトークンを当てる」

例えば,

日本の首都は _____

に対して,

- 東京：高い確率
- 京都：低い確率
- バナナ：非常に低い確率

となるように学習する。

「次を当てる」を繰り返す

文章を生成するときも、基本は同じである。

- ① これまでの文章を読む
- ② 次のトークンの確率を計算する
- ③ 次のトークンを選ぶ
- ④ そのトークンを文章に追加する
- ⑤ また次を予測する

これを何度も繰り返すことで、長い文章を生成する。

なぜ「何でも知っている」ように見える？

GPT は、大量の文章を使って「次を当てる」学習を繰り返す。

正確に予測するためには、

- 単語の使い方
- 文法
- 文章の構造
- 世の中について書かれた情報
- 質問と回答のパターン
- プログラムの書き方

など、さまざまな規則性を利用する必要がある。

その結果、

多くのことを知っているように振る舞える

ようになる。

GPT には目と耳がある？

最近の ChatGPT は、テキスト以外も扱うことができる。

- 画像
- 音声
- 動画

しかし、GPT がそのまま「目」や「耳」を持っているわけではない。

ポイントは、

異なる情報を、Transformer が扱える表現に変換する

ことである。

画像も「数字」にする

テキストでは、トークンを数字に変換した。

画像でも基本的な考え方は同じである。

- 画像を小さな領域などに分ける
- 画像の特徴を数字として表現する
- Transformer が扱える形に変換する

つまり、

テキストも画像も、最終的には「数字の表現」として扱われる

マルチモーダルモデル

テキスト, 画像, 音声など, 複数種類の情報を扱うモデルを

マルチモーダルモデル

と呼ぶ.

- 画像を見て説明する
- 写真について質問に答える
- 音声を聞いて文章にする
- テキストと画像を組み合わせて推論する

Transformer は, 「文章だけ処理する仕組み」というより,

さまざまな情報の関係を扱える仕組み

と考えることができる.

それでも間違う！

GPT は非常に多くのことを答えられる.

しかし,

- 存在しない論文を紹介する
 - 間違った歴史的事実を説明する
 - 計算を間違える
 - 自信満々に誤った説明をする
- ことがある.

このように、もっともらしい誤った内容を生成する現象を

ハルシネーション

と呼ぶ.

なぜ間違える？

GPT の目的は,

「世界について正しい文章を書くこと」

ではなく,

「文脈から次に来そうなトークンを予測すること」

そのため,

- 文章として自然
- 文法的にも正しい
- 一見もっともらしい

だけど

事実として正しいとは限らないという問題がある.

間違いを減らすには？

ハルシネーションを完全になくすことは難しいが、減らす方法はある。

使い手側

- 出典を確認する
- 重要な情報は裏取りする
- 条件を明確に伝える
- AI の回答を鵜呑みにしない

システム側

- 検索結果を参照させる
- データベースを利用する
- 外部ツールで計算する
- 回答を検証する仕組みを入れる

3つの疑問を振り返る

最初の3つの疑問に戻ってみる.

- **なんで「何を質問しても知っている」のか**
 - 大量の文章から、次のトークンを予測する学習をしているから
- **なんで画像なども扱えるのか**
 - 画像なども数値表現に変換し、Transformer で扱えるから
- **なんで間違えることがあるのか**
 - 「正しい答え」ではなく、「もっともらしい次」を予測しているから

ChatGPT の "T" って？

Transformer は,

情報同士の関係を見ながら,
文脈に応じた表現を作る仕組み

そして GPT は,

その Transformer を使って
「次に何が来るか」を学んだモデル

まとめ

- Transformer は単語同士の関係を捉える
- Attention が文脈に応じた重要度を計算する
- 現在の大規模言語モデルを支える基盤技術である

皆さんから、追加の質問はありますか？